

Feuille de route — Cas d'usage certif

Bank Marketing — « cibler une campagne bancaire de manière responsable » (UCI Bank Marketing) · apprenant·e **Dev-id** · le plan de vol : quoi faire maintenant, quoi attendre, quelle fiche ouvrir à quel moment.

Les 4 documents à garder ouverts en permanence

- 1 **Le sujet d'examen** (Bank Marketing) — ta commande, tes scénarios 1→4, tes questions RGPD & équité à traiter.
- 2 `canvas-cas-usage-v2.ipynb` — la trame de ton notebook final (tes sections = ses sections).
- 3 `journal-de-bord.ipynb` — à remplir **dès aujourd'hui**, à chaque session (livrable certif, pas une option).
- 4 Cette feuille de route.

1 Le principe : 2 parties, calées sur ton calendrier

PARTIE 1 · ÉTÉ · EN AUTONOMIE (M0-M3)
Phases 1 → 5 (+ API basique)
Cadrage, EDA, éthique, préparation sans fuite, **benchmark des 4 scénarios**, arbitrages. Puis, en option, une API `/predict` + `/health` (ton squelette M1-B2).
= sections 0 à 7 du canvas

PARTIE 2 · RENTRÉE · AU FIL DES MODULES (M4→M8)
Phases 6bis → 8
Fiabiliser (Pydantic, logs, Docker, CI/CD, MLflow), **surveiller** (monitoring, dérive, réentraînement), **architecturer** (archi cible, on-premise vs cloud, soutenance).
= sections 8 et 9 du canvas

22/07 fin M3 → chantier été (phases 1→5)	pause jusqu'au 18/08	18-26/08 M4 + M5 en bloc → modèle affiné + industrialisation (6bis)	~2 sem. consolider, pas ouvrir un chantier	15-16/09 M6 → monitoring, drift, feedback (phase 7)	21/09→07/10 M7-M8 → architecture (phase 8)	19-21/10 oraux
--	--------------------------------	---	--	---	--	--------------------------

FASTAPI, TU L'AS DÉJÀ (M1-B2) — une API minimale (`/predict` qui renvoie la probabilité de souscription + `/health`) est **faisable dès cet été**. Mais tout ce qui la **fiabilise** (validation stricte, gestion d'erreurs, journalisation, Docker, CI/CD, MLflow, réentraînement) attend **M5-M6** : tu le construirais mal et deux fois.

⚠ **LE PIÈGE N°1 DES PROFILS IT** — foncer sur Docker/CI-CD (ta zone de confort) et garder la modélisation « pour plus tard ». **C'est l'inverse qu'il faut faire** : la modélisation et **l'analyse comparée des 4 scénarios** sont la partie la plus longue à mûrir, et c'est elle qui alimente tout le reste — y compris tes réponses éthiques.

2 Les 8 phases

Partie 1 — cet été, en autonomie (fiches déjà dans ton repo, dossier `ressources/`)

#	PHASE	CANVAS	TU PRODUIS	VU EN	STATUT
1	Cadrer	\$0-\$1	Cadrage écrit, dictionnaire des risques (RGPD, ciblage discriminant), setup traçabilité (versions, hash du CSV, git).	M0, M2	✅ faisable
2	Explorer	\$2-\$3	EDA + audit qualité (<code>unknown</code> , cardinalités, <code>pdays=999</code> , déséquilibre ~11 %), analyse de biais par sous-groupe (âge, profession).	M2, M3	✅ faisable
3	Préparer	\$4	Pipeline sans fuite (split d'abord) + <code>ColumnTransformer</code> , les 4 scénarios régénérables, assertions qualité (§4.5).	M3	✅ faisable
4	Modéliser & comparer	\$5	Benchmark multi-modèles × 4 scénarios en validation croisée stratifiée , test scellé, gestion du déséquilibre (<code>class_weight</code> , seuil).	M1	✅ faisable
5	Arbitrer	\$6-\$7	Verdict chiffré perf × éthique × robustesse ; choix argumenté du modèle ET du jeu de variables ; fallback/seuils (erreurs critiques, human-in-the-loop).	M1, M2	✅ faisable

#	PHASE	CANVAS	TU PRODUIS	VU EN	STATUT
6	Exposer (basique)	\$8.1-8.2	Persistence <code>joblib</code> + API FastAPI minimale qui charge le pipeline et renvoie la probabilité.	M1	faisable

Partie 2 — à la rentrée, au fil des modules (fiches ajoutées à la rentrée 📖)

#	PHASE	CANVAS	TU PRODUIS	VU EN	STATUT
6bis	Fiabiliser	\$8.5	Validation Pydantic stricte, gestion d'erreurs, middleware de log, tests, <code>Dockerfile</code> , GitHub Actions, tracking MLflow.	M5	fin août
7	Surveiller	\$9	Métriques techniques (latence, erreurs, dispo) + métier (écart taux réel / proba, dérive du profil), critères de réentraînement, champion/challenger, tableau de bord.	M6	mi-sept
8	Architecturer & défendre	\$8.4 + dossier	Schéma d'archi cible, on-premise vs cloud souverain, acteurs à consulter (SI, DPO, métier), dimensionnement, dossier + slides.	M7, M8	sept-oct

LE JOURNAL DE BORD TRAVERSE LES 8 PHASES — à chaque session : ce que tu as fait, ce qui t'a bloqué, ce que tu as **décidé et pourquoi** (surtout : *pourquoi ce scénario, pourquoi retirer telle variable*). Un arbitrage noté à chaud (phase 5) est bien plus solide à défendre en octobre qu'un souvenir reconstruit.

L'éthique est dans le fil, pas en annexe

- Traite-la **au fil de l'eau**, aux endroits prévus du canvas : **\$1.5** (risques au cadrage) → **\$3.6** (biais par sous-groupe dans l'EDA) → **\$4.3 / \$6** (lecture éthique des 4 scénarios).
- Les questions précises (nature des données, base légale, équité par groupe) sont **dans le sujet** : à toi de les instruire.

Cet été : fais / ne fais pas

- ✓ Phases 1→5 dans l'ordre → arriver au 18/08 avec un **benchmark des 4 scénarios + arbitrage argumenté**.
- ✓ Journal à chaque session · éthique au fil de l'eau · galerie de réentraînement pour t'entraîner.
- ✗ Docker/CI-CD/MLflow/monitoring avant M5-M6 · conclure sur un seul split · te fier à l'exactitude sur cible déséquilibrée · tuner avant une baseline honnête.
- ✗ Oublier **≥ 2 semaines OFF** : de vraies vacances font partie du plan.

Mini-jalons : fin ph.2 = EDA complète + 1er écart par sous-groupe · fin ph.3 = fit sans fuite + 4 scénarios régénérables · fin ph.4 = Un doute → Discord Dev-id ou RDV du vendredi.
tableau modèlesxscénarios reproductible · fin ph.5 = défendre ses choix en 2 min.